

LLM Agent 辅助高风险多属性决策：基于建构性偏好与认知脚手架的跨学科理论框架

在当前的人工智能与人机交互 (Human-Computer Interaction, HCI) 以及运筹学交叉领域, 大型语言模型 (LLM) 驱动的智能 Agent 正在经历从“被动指令执行器”向“主动决策导航伙伴”的范式跃迁。在诸如高考志愿填报、复杂医疗干预方案选择、重大金融资产配置等典型的高风险、多属性决策 (Multi-criteria Decision-Making, MCDM / Multi-attribute Decision Analysis, MCDA) 场景中, 传统的决策支持系统面临着深刻的理论与工程瓶颈¹。这些传统系统高度依赖“揭示偏好 (Revealed Preferences)”假设, 将用户在交互初期输入的约束条件视为绝对的、静态的效用底线。

然而, 真实的系统运行与行为工程观察揭示了一个普遍存在的悖论: 用户在面对高风险多属性组合优化问题时, 其初始的系统输入往往呈现出极度“过度约束 (Over-constrained)”的特征 (例如, 在高考志愿填报中表现为“绝不跨省”、“只要特定热门专业”等刚性红线)。这种现象不仅导致传统数据库查询频繁遭遇无解 (Infeasible Queries) 状态², 更使其陷入局部次优解的陷阱。带有高级推理能力的 LLM Agent 并不盲从这些防御性条件, 而是通过动态检索与多跳推理, 主动寻找并向用户呈现反事实数据证据 (Counterfactual Evidence, 例如: “如果放宽省份限制, 你可以被某所 985 顶尖院校的核心专业录取”)。通过发起这种“妥协谈判”, Agent 成功突破了显式偏好的表层硬壳, 触发并重塑了用户的“隐性偏好 (Implicit Preferences)”。

本报告将系统性地解构这一现象的深层机制。通过深度融合行为经济学、认知心理学与行为决策理论 (Behavioral Decision Theory, BDT), 本研究旨在将这一启发式的工程设计上升为严谨的系统学方法论, 论述在极高认知负荷与不确定性约束下, LLM Agent 是如何利用数据驱动的反事实干预, 克服人类锚定效应, 并作为认知脚手架引导决策者逼近全局最优效用的。

一、显式偏好的幻象：建构性偏好与有限理性下的过度约束机制

要理解用户为何在初始阶段设定过度约束, 首先必须剥离新古典经济学 (Neoclassical Economics) 中关于“理性人”与“稳定偏好”的传统假设, 转而将人类的决策行为置于有限信息处理能力与高度心理防御的真实情境中进行考察。

1. 从“价值发现”到“建构性偏好”的理论转向

传统理性选择理论 (Rational Choice Theory) 及效用最大化模型假定, 决策者的大脑中存储着一个完备的、具有内部一致性且满足传递性公理的效用函数。在这一理论框架下, 偏好获取被视为一个纯粹的“价值发现 (Value Discovery)”或“考古 (Archaeological)”过程——即用户的偏好如同深埋地下的化石, 系统只需通过恰当的查询接口将其完好无损地挖掘并映射到计算空间中³。若此假设成立, 系统理应严格且机械地执行用户的每一项硬性约束。

然而, 行为决策理论的奠基人之一 Paul Slovic 等通过大量实证研究彻底颠覆了这一预设, 提出了“建构性偏好 (Constructed Preferences)”理论³。Slovic 用棒球裁判的三种境界来隐喻人类对价值的认知: 第一种是客观反映 (“我怎么看就怎么判”); 第二种是内在固有知识 (“事实如何我就怎么判”); 第三种则是建构主义视角 (“在我不作评判之前, 它们什么都不是”) ³。在面对涉及海量选

项、陌生环境且各属性(如院校层级、地理位置、专业就业前景)存在激烈内部冲突的高风险 MCDM 问题时,普通用户实际上并不具备预先定义好的显式偏好结构¹。

在高考志愿填报场景中,绝大多数考生和家长是典型的“生手决策者”。面对数千所高校和极其复杂的组合博弈,他们的真实偏好高度依赖于决策环境、选项的呈现框架(Framing)以及即时的认知诱导³。所谓的“绝不跨省”,并非通过严密计算得出的绝对效用阈值,而是在庞大信息压力下,用户在与系统交互的瞬间被临时“建构”出来的粗糙启发式(Heuristic)防线。系统如果盲目遵循这种未成熟的建构物,实质上是放任了决策质量的劣化。

2. 有限理性(Bounded Rationality)与认知维度的急剧降维

Herbert Simon 的有限理性理论进一步为“过度约束”的产生提供了认知资源层面的解释。该理论指出,人类的工作记忆与信息处理带宽是极其有限的,无法在呈现指数级爆炸的组合解空间中执行全局最优化(Optimization)运算。因此,人类倾向于退而求其次,采用“满意原则(Satisficing)”⁸。

当面对高考志愿这种不仅数据量庞大,且具备极高认知复杂度的任务时,用户会本能地调用非补偿性策略(Non-compensatory Strategies)来进行空间剪枝¹⁰。设定“绝不跨省”或“只要热门专业”等刚性过度约束,在认知心理学上是一种极其高效的“一票否决”机制。它能在一瞬间将需要深入评估的院校数量从数千所骤降至几十所,从而将任务难度强行拉回人类工作记忆可承受的极限内。因此,这些约束条件在初期并非表达了用户对省外高校的极度厌恶,而是体现了大脑在面对计算灾难时启动的紧急“认知降维”机制。


3. 高风险语境下的“防御性决策”与损失规避

除了认知资源的局限外,过度约束更深层的动机来源于心理层面的安全诉求。Gerd Gigerenzer 等学者深入探讨了高风险环境下的“防御性决策(Defensive Decision Making)”现象¹¹。在极高不确定性且后果极其严重的决策中,个体往往被“损失规避(Loss Aversion)”与“指责/后悔规避(Blame Avoidance)”所主导。

这一现象在商业和公共管理中被称为“希思罗效应(Heathrow Effect)”——为了规避潜在的失败责任,决策者倾向于选择默认的、看似最安全的选项,即使该选项在客观效用上显著次优¹¹。将这一理论映射到志愿填报场景,异地求学意味着对陌生气候、文化冲突、地方保护主义及未知人际网络的暴露。“未知”在人类进化心理学中往往等同于“威胁”。设定“绝不跨省”的边界,实际上是建立了一道心理防线。只要留在本地,即使院校层级下降,也是一种“安全且合乎社会默认预期”的妥协,可以最大程度避免未来因适应不良而产生的严重懊悔。

因此,当传统查询系统遭遇这种由防御性决策机制构建的查询语句时(即查询常常返回空集或极差的匹配),一味要求用户自行修改参数不仅无效,反而会加剧其焦虑感²。必须依赖具备逻辑推理与知识整合能力的 AI 介入,通过外部实证来打破这种防御。

反事实干预对决策效用边界的拓展效应



横轴代表用户与系统的交互轮次，纵轴代表决策选项的综合期望效用。在传统系统中，由于恪守用户的防御性约束，效用迅速触及天花板；而引入反事实数据干预的 Agent 能够通过松弛约束，将用户引导至更高的效用空间。

Data sources: [Survey: Combining Constraint Programming and Machine Learning, Interactive and personalized preference elicitation](#)

二、突破认知锚点：反事实数据证据的干预与去偏机制

当系统识别到由防御机制引发的过度约束严重压缩了可行解空间时，智能 Agent 主动挖掘并在对话中抛出具体的高价值选项（“如果放宽省份，可以上 985”）。这一看似简单的工程交互，在底层实际上执行了极其精密的心理学“去偏 (Debiasing)”与运筹学“约束松弛 (Constraint Relaxation)”干预。

1. 约束条件固化为绝对锚点 (Anchoring Effect)

一旦用户在系统中显式输入了初始偏好，这些约束立刻在心理层面上演变为一种难以撼动的“锚定效应 (Anchoring Effect)”¹⁵。认知心理学自 20 世纪 70 年代以来的大量研究证实，决策者在处理复杂信息时会过度依赖最初获得的信息锚点，并且在后续调整时往往显得不足¹⁵。在人机协同环境中，由人类文本输入构成的语义锚点不仅约束了底层算法的寻优空间，也锁死了人类自身的认知解释框架¹⁵。

值得注意的是，传统的去偏策略在对抗强烈的锚定效应时通常是失效的。研究表明，单纯的显式警告 (Explicit Warnings)、要求增加认知努力或提供泛泛的领域专业建议，均无法显著降低锚定偏

差¹⁶。这意味着系统用系统消息冷冰冰地提示“条件过严，请放宽搜索限制”，几乎不可能促使用户真正改变初衷，反而会触发用户的抵触情绪，认为系统智能化水平低下。

2. 反事实思维(Counterfactual Thinking)的深度去偏路径

在上述僵局中，Agent 生成的具体数据证据起到了破局作用。通过构造一个极其诱人的“假设如果(What-if)”情境，系统在计算逻辑上执行了“算法求偿(Algorithmic Recourse)”¹⁸，即向用户提供一条如何通过最少妥协来推翻不良决策现状的行动路径；而在认知心理学层面，这强制激活了用户的“反事实思维(Counterfactual Thinking)”。

反事实思维是指人类对违背既定事实或假设前提的替代性结果进行心理模拟的过程。在行为科学中，“考虑替代方案(Considering the Alternative 或 Considering the Opposite)”被公认为是少数几种能够有效补偿选择性可及性(Selective Accessibility)偏差、削弱锚定效应的有力工具¹⁹。Agent 提供的具有极高“影子价格(Shadow Price)”的具体实例，通过两条并行的心理路径(Pathways)实现了对用户的深度去偏²¹：

- **内容特定路径(Content-Specific Pathway)**：在此路径下，反事实内容的具体属性直接产生作用。当用户看到“985 顶尖专业”这一具象化、高阶效用的数据时，该证据作为一种强烈的正向诱发物，打破了原来的心理会计平衡。用户被强迫直面一种显性的机会成本计算：坚守“不跨省”这一防御性底线的真实代价，是放弃肉眼可见的阶层跃升与优质教育资源。具象的数据(而非抽象的建议)提供了足够的动机，让用户重新衡量防御性风险与显著预期收益之间的权重关系。
- **内容中立的心智模式转变(Content-Neutral Pathway)**：更为关键的是，反事实干预能够在超越当前具体数据的层面上，改变决策者整体的认知模式。研究发现，反事实的生成能够改变决策者的搜索策略，促使他们进入一种“反事实心智模式(Counterfactual Mind-set)”²¹。处于这种心智状态的决策者，其认知唤醒水平显著升高，表现出更强烈的意愿去寻找和评估那些违背其初始信念的非证实性信息(Disconfirmatory Information)²²。他们更倾向于放松认知闭合(Cognitive Closure)，卸下心理防御，从而使得原本被掩盖的深层核心偏好(追求长期职业回报与名校光环)浮出水面。

通过这一机制，智能 Agent 不再是机械的过滤器，而是成为了一个心理学意义上的行为干预者。它利用确凿的、个性化的数据证据作为杠杆，帮助受困于局部极小值(Local Minimum)的用户跳出了由自身认知盲区画下的牢笼。

三、认知脚手架：AI Agent 在人机决策博弈中的角色重构

上述通过反事实证据引发妥协并重塑偏好的过程，本质上要求一种高度动态、双向博弈的系统架构。在这套架构中，LLM Agent 已经完全脱离了传统信息系统的定位，转而扮演了现代 HCI 理论中所倡导的“认知脚手架(Cognitive Scaffolding)”角色。


1. 从事务性交互到对话式心智模型

“脚手架(Scaffolding)”概念最初源自发展心理学家 Vygotsky 关于学习过程的理论，指的是一个能力更强的指导者通过提供适时的、渐进的结构化支持，帮助个体跨越“最近发展区”，完成其无法独立完成的复杂任务²³。在当代人机交互语境下，认知脚手架演变为系统通过表征设计与交互约

束，影响用户的注意力分配、因果推理和自我调节能力²³。

在高风险的数字环境中，用户习惯于将 AI 视为一种单向度工具，抱有一种“事务性心智模型 (Transactional Mental Model)”——即进行一次设定，期待获取完美答案²⁶。然而在复杂的偏好权衡中，这种“一击必中”的期望必然落空。具备认知脚手架功能的 Agent 能够引导用户实现心智模型的根本性转变，使其进入一种“对话式心智模型 (Dialogic Mental Model)”²⁶。通过发起妥协谈判，系统并不急于输出最终裁决，而是将决策过程拉长，在每一个反事实选项的反馈循环中，训练用户权衡多维属性的能力。

从被动响应到认知脚手架：决策范式的架构演变



传统事务性模型（上）盲目接受显式约束，导致决策陷入死胡同；而 AI 认知脚手架模型（下）通过生成反事实数据并引入适度的结构性摩擦，引导用户进入“约束松弛—偏好重构”的迭代博弈，最终触达真实的隐性偏好区。

2. 外部反射、建设性摩擦与偏好渐进启发

具体而言，智能 Agent 在构建认知脚手架时展现了三个维度的核心功能：

- 认知延伸与外部化反射 (Externalization Effect)：在人类的内部脑海中，将“离家的距离”与“未来的就业薪酬”这两种具有完全不同量纲和时间跨度的属性进行折算，会耗尽有限的工作记忆，导致认知超载²⁸。Agent 的作用在于将这种隐晦的内部纠结外部化。通过语言模型强大的模式识别与文本生成能力，系统将高维数据凝练为通俗易懂的对比文本，就像一面高分辨率的镜子，映照并拓展了用户尚未完全理清的逻辑链条²⁸。

- 引入建设性摩擦(Germane Friction)与“魔鬼代言人”机制:近年来 HCI 领域的前沿反思指出,过度顺从用户的 AI 会剥夺人类的认知能动性,导致认知懒惰与自动化偏见(Automation Bias)³⁰。相反,一个合格的脚手架必须主动引入适度的阻力。Agent 通过系统地暴露结构性分歧(Structured Disagreements)——即展示违背用户意愿但极具诱惑力的数据,扮演了“魔鬼代言人(Devil's Advocate)”的角色³¹。这种刻意制造的“建设性摩擦(Germane Friction)”,有效打破了人类试图尽早完成任务的认知闭合,强行将决策的判断中枢拉回人类的前额叶皮层,保障了高风险决策中的人类自主性²⁴。
- 渐进式偏好启发(Progressive Preference Elicitation):如果系统一开始就要求用户对复杂的权重指标进行全局性的精细打分,会立即引发用户的疲劳效应与抗拒心理³²。Agent 巧妙地采用了增量与分布式的策略。它首先宽容地接受用户粗糙的启发式偏好,随后在多轮交互中,针对具体的矛盾点进行微小的试探与启发(如:“在这个局部选项上,您愿意牺牲 A 来换取 B 吗?”)⁷。这种将宏大权衡拆解为局部具体对比的方法,有效地将系统内在的不确定性转换为用户可控的增量反馈,从而在维持极低外部认知负荷的同时,精准地测绘出人类真实的非线性效用曲面³⁴。

四、核心方法论的学术专业术语提炼

为了在学术论文的撰写中,能够高屋建瓴地概括“AI 通过数据证据反向启发并重塑人类隐性偏好”这一复杂的系统级行为,本报告基于上述理论分析,提炼并严谨定义了以下五个跨学科的学术专业术语。这些术语可作为论文标题、小节摘要或机制命名的核心元素。

核心术语	英文全称 (缩写)	学术根基与应用场景说明
反事实驱动的偏好建构	Counterfactual-Driven Preference Construction (CDPC)	学术根基:融合 Slovic 建构性偏好理论 ³ 与认知心理学反事实去偏理论 ¹⁹ 。说明:此术语可作为整套机制的宏观理论统称,精准概括了“人类偏好并非静态存在等待检索,而是通过外部反事实刺激的介入,在动态博弈中被逐步塑造成型”的本质特征。
启发式约束松弛博弈	Heuristic Constraint Relaxation Game (HCRG)	学术根基:结合运筹学“约束松弛” ³⁷ 、有限理性启发式 ³⁹ 及博弈论交互模型 ⁴⁰ 。说明:适合用于描述算法层面的交互协议。强调用户早期的输入并非绝对真理,而是一种心理防御下的“启发式”草稿;

		Agent 在寻找可行解时，与用户进行的是一场寻找最优约束边界的动态博弈过程。
隐性效用的算法启迪	Algorithmic Elicitation of Implicit Utility (AEIU)	学术根基：源自多属性效用理论 (MAUT) 与交互式偏好启发 ³³ 。说明：用于定性描述数据挖掘与推荐机制模块。突显了智能算法在不直接违抗用户指令的前提下，如何通过精巧的设计“诱导 (Elicitation)”并测算那些深藏于潜意识、难以被直接声明的效用红利。
建设性认知摩擦与脚手架导航	Germane Cognitive Friction and Scaffolded Navigation (GCF-SN)	学术根基：植根于人机交互 (HCI) 与教育心理学中的脚手架理论 ²⁴ 。说明：专门服务于论文的人机协同与界面交互章节。强调为了避免认知自动化与退化，AI 必须通过引入对立视角的“建设性摩擦”，充当复杂决策迷宫中的认知导航员。
边界突破性元推理	Boundary-Breaking Meta-Reasoning (BBMR)	学术根基：基于有限理性框架内的元推理机制 ⁹ 及对锚定效应的克服 ²² 。说明：用于剖析用户在接受系统干预后发生的深层心理变化。刻画了决策者从盲目遵循初始设定，到开启高阶“元认知 (Metacognition)”去重新审视、推翻自身不合理防御边界的过程。

五、奠基性与前沿高质量文献支撑体系

构建坚实的理论逻辑必须建立在严谨的学术传承之上。以下文献矩阵精选了从经典理论奠基到近期顶会 (Top-tier Conferences) 及顶刊的代表性著作，涵盖了建构性偏好、有限理性、反事实去偏以及大语言模型在 HCI 中的认知延伸应用。这些文献共同为本报告提出的框架提供了无懈可击的学术合法性支撑。

作者与年份	来源期刊 / 会议	论文名称与核心理论贡献	理论对应度与应用方向
Slovic, P. (1995)	<i>American Psychologist</i>	《 The Construction of Preference 》 ³ 核心论点:人类在面对多属性、高风险决策时,并不拥有稳定的内部效用结构。偏好是高度脆弱的,极易受环境、表达框架和提取方式的影响,是在决策现场“被建构”的。	底层合法性基石:该文献为系统“不盲从用户输入”提供了最权威的心理学区辩护。证明基于选项博弈重塑偏好是顺应认知规律的科学做法。
Gigerenzer, G. & Selten, R. (2001) / Gigerenzer (2005)	MIT Press / 及其后续关于防御性决策的著作	《 Bounded Rationality: The Adaptive Toolbox 》等 ¹⁰ 核心论点:扩展了“有限理性”框架,提出人类倾向于使用极简的“启发式(Heuristics)”。并在高风险语境中揭示了“防御性决策”,即决策的首要目的往往是推卸责任与规避未知风险,而非效用最大化。	异常行为的理论溯源:完美解释了为何考生在志愿系统中会写出“绝不跨省”这种非理性的绝对约束——这是避免错误决策带来巨大懊悔的进化本能防御。
Kray, L. J. & Galinsky, A. D. (2003) / Roese (1997)	<i>Organizational Behavior and Human Decision Processes / Psychological Bulletin</i>	《 The debiasing effect of counterfactual mind-sets: Increasing the search for disconfirmatory information... 》 ²¹ 核心论点:通过实验确立了反事实思维不仅能纠正特定内容	干预手段的心理学实证:直接支撑了通过 Agent 呈现“放宽条件可上 985”这一反事实数据,从而有效摧毁“锚定效应”并软化用户谈判态度的机制假设。

		的偏差,更重要的是能激活“反事实心智模式”,大幅提升人类放弃原有信念、接纳非证实性客观事实的意愿。	
De Toni, G. et al. (2023)	International Conference on Machine Learning (ICML)	《Personalized algorithmic recourse with preference elicitation》 ¹⁸ 核心论点:提出了在解释性人工智能(XAI)领域,如何通过“算法求偿(Algorithmic Recourse)”结合蒙特卡洛树搜索,利用反事实解释引导用户通过微调输入来推翻不良决策结果,且有效评估用户的调整代价。	工程机制的算法学背书:展示了计算机科学前沿是如何通过数学建模,运用反事实手段在对话中动态提取偏好边界的,与您的系统架构高度契合。
Wang, D. et al. (2025) / Dalsgaard, P. (2025)	Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI 2025) / ECCE 2025	《Scaffolding algorithmic programming learning through learner-LLM co-decomposition》等 ²⁴ 核心论点:当代 HCI 研究前沿将 LLM 重新定义为不仅是任务自动化工具,更是促进人类“元认知”发展的“认知脚手架”。强调了在使用生成式 AI 时,必须保留结构性摩擦以保障思维的深度。	人机协作范式前沿对标:将“妥协谈判 Agent”置于最新的人工智能与人类学交叉语境下,拔高了系统设计的社会学与认知科学意义。

六、综合性论断与应用前景展望

在包括高考志愿填报在内的高风险、多属性决策域中，决策者长期受困于认知能力受限与心理防御过当的双重桎梏。传统的决策支持范式因机械恪守“揭示偏好”的教条，未能洞察人类在不确定性迷雾中产生“过度约束”的真实动机，往往沦为固化认知盲区的放大器。

本研究论证了，引入具备反事实数据生成与协商能力的 LLM Agent，标志着一次根本性的方法论革新。该机制精准锚定了建构性偏好的脆弱本质，通过投放具有显著“影子价格”的高价值证据作为“建设性摩擦”，成功在用户脑内触发了反事实心智的去偏路径。在这一动态的约束松弛与博弈循环中，Agent 超越了单纯的检索工具定位，上升为引导人类跨越认知闭合障碍、重塑隐性偏好边界的“认知脚手架”。

这种被高度提炼为反事实驱动的偏好建构 (CDPC) 的人机协同新范式，不仅为现有的智能决策支持系统提供了坚实的跨学科理论解释，更预示着人工智能的发展终局并非在于彻底替代人类进行价值判断。相反，机器智能的最高价值，在于其能够凭借强大的数据处理广度，温柔地打破人类因防御本能而划下的局部最优边界，反向启迪并协助人类构建出更接近真实效用最大化的理性选择体系。这一理论框架为未来金融风控、临床医疗方案制定、甚至公共政策协商等更广阔的强博弈领域，提供了极具拓展潜力的系统架构蓝本。

Works cited

1. Multiple-criteria decision analysis - Wikipedia, accessed May 12, 2026, https://en.wikipedia.org/wiki/Multiple-criteria_decision_analysis
2. An introduction to reasoning over qualitative multi-attribute preferences - Maximum Academic Press, accessed May 12, 2026, <https://maxapress.com/data/article/ker/preview/pdf/S0269888915000016.pdf>
3. The Construction of Preference - Information Technology at Warrington, accessed May 12, 2026, <http://bear.warrington.ufl.edu/brenner/mar7588/Papers/slovic-ampsy1995.pdf>
4. Beyond Preferences in AI Alignment - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2408.16984v1>
5. Constructed Preferences, Rationality, and Choice Architecture, accessed May 12, 2026, https://rady.ucsd.edu/_files/faculty-research/mckenzie/McKenzieetal2018RevBehavEcon.pdf
6. Attention and Reference Dependence - Carnegie Mellon University, accessed May 12, 2026, <https://www.cmu.edu/dietrich/sds/docs/golman/Attention%20and%20Reference%20Dependence-%20December2015.pdf>
7. “I Want It That Way”: Enabling Interactive Decision Support Using Large Language Models and Constraint Programming - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2312.06908v2>
8. The Construction of Preference, by Paul Slovic - Jon Kolko, accessed May 12, 2026, <https://www.jonkolko.com/phd/writing/25-06-27-construction-of-preference>

9. (PDF) Metareasoning and Bounded Rationality - ResearchGate, accessed May 12, 2026,
https://www.researchgate.net/publication/228529373_Metareasoning_and_Bounded_Rationality
10. fast and frugal heuristics - MPG.PuRe, accessed May 12, 2026,
https://pure.mpg.de/pubman/item/item_2101183_5/component/file_2101182/GG_Fast_2005.pdf
11. Rory Sutherland — Solving Real World Commercial Challenges Through Human Irrationality and Behavioral Science | by Ankit Morajkar | Medium, accessed May 12, 2026,
<https://medium.com/@ankit1597/rory-sutherland-solving-real-world-commercial-challenges-through-human-irrationality-and-f4e0461a0fdb>
12. General-Purpose Institutional Decision-Making Heuristics: The Case of Decision-Making under Deep Uncertainty | The British Journal for the Philosophy of Science, accessed May 12, 2026,
<https://www.journals.uchicago.edu/doi/10.1086/722307>
13. Intelligence and Decision-Making (Chapter 24) - Cambridge University Press & Assessment, accessed May 12, 2026,
<https://www.cambridge.org/core/books/cambridge-handbook-of-intelligence/intelligence-and-decisionmaking/D4F6A28EE22E4742A7FC94128E4F65A3>
14. ORPilot: A Production-Oriented Agentic LLM-for-OR Tool for Optimization Modeling - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2605.02728v1>
15. What Is Social Context Anchoring Bias in AI Agents? - MindStudio, accessed May 12, 2026,
<https://www.mindstudio.ai/blog/social-context-anchoring-bias-ai-agents>
16. When It's Bad to Be Lucky: Observers' Judgments of Fortuitous Victims - Taylor & Francis, accessed May 12, 2026,
<https://www.tandfonline.com/doi/full/10.1080/01973533.2020.1863797>
17. Low Power, First Offers, and Reservation Prices: Weak Negotiators are Self-anchored by their Own Alternatives ; - MIT Press Direct, accessed May 12, 2026, <https://direct.mit.edu/ngtn/article-pdf/39/1/7/2375276/nej012423.pdf>
18. Personalized Algorithmic Recourse with Preference Elicitation - SML group, accessed May 12, 2026, http://sml.disi.unitn.it/files/hldm23/HLDM23_340.pdf
19. How Can Debiasing Research Aid Efforts to Reduce Discrimination? - PMC, accessed May 12, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11734358/>
20. Is it time for studying real-life debiasing? Evaluation of the effectiveness of an analogical intervention technique - PMC, accessed May 12, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC4523707/>
21. The Functional Theory of Counterfactual Thinking - PMC, accessed May 12, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC2408534/>
22. The debiasing effect of counterfactual mind-sets: Increasing the search for disconfirmatory information in group decisions | Request PDF - ResearchGate, accessed May 12, 2026,
https://www.researchgate.net/publication/222830434_The_debiasing_effect_of_counterfactual_mind-sets_Increasing_the_search_for_disconfirmatory_information

[in_group_decisions](#)

23. A Macrocognitive Design Taxonomy for Simulation-Based Training Systems: Bridging Cognitive Theory and Human-Computer Interaction - ODU Digital Commons, accessed May 12, 2026, https://digitalcommons.odu.edu/cgi/viewcontent.cgi?article=1001&context=vdmc_pubs
24. Scaffolding Metacognition in Design with Generative AI - DRS Digital Library, accessed May 12, 2026, <https://dl.designresearchsociety.org/cgi/viewcontent.cgi?article=1596&context=iasdr>
25. Scaffolding Human Champions: AI as a More Competent Other, accessed May 12, 2026, <https://d-nb.info/1366022211/34>
26. Scaffolding Human-AI Collaboration: A Field Experiment on Behavioral Protocols and Cognitive Reframing - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2604.08678v2>
27. AI-based Verbal and Visual Scaffolding in a Serious Game: Effects on Learning and Cognitive Load - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2602.08893v1>
28. AI as Cognitive Scaffolding: Why Language Models Work Better as Mirrors– Not Therapists, accessed May 12, 2026, <https://peelingfacade.medium.com/ai-as-cognitive-scaffolding-why-language-models-work-better-as-mirrors-not-therapists-7784951eb93f>
29. Are we moving from “AI tools” to AI cognitive scaffolding / exoskeletons? - Reddit, accessed May 12, 2026, https://www.reddit.com/r/ArtificialIntelligence/comments/1q0swz8/are_we_moving_from_ai_tools_to_ai_cognitive/
30. Human-AI Interactions in Public Sector Decision Making: “Automation Bias” and “Selective Adherence” to Algorithmic Advice - Oxford Academic, accessed May 12, 2026, <https://academic.oup.com/jpart/article/33/1/153/6524536>
31. Cognitive Agency Surrender: Defending Epistemic Sovereignty via Scaffolded AI Friction, accessed May 12, 2026, <https://arxiv.org/html/2603.21735v1>
32. A Survey on Preference-Based Multi-Objective Evolutionary Algorithms - MDPI, accessed May 12, 2026, <https://www.mdpi.com/2227-7390/14/8/1365>
33. Preference reasoning with soft constraints in constraint-based recommender systems, accessed May 12, 2026, https://www.researchgate.net/publication/220202346_Preference_reasoning_with_soft_constraints_in_constraint-based_recommender_systems
34. Recommender Systems Should Now Be Designed Towards Agents, accessed May 12, 2026, <https://www.preprints.org/manuscript/202604.0201>
35. Ethics of the algorithmic prediction of goal of care preferences: from theory to practice - PMC, accessed May 12, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9985740/>
36. What matters to me – a web-based preference elicitation tool for clients in long-term care: a user-centred design - PMC, accessed May 12, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7077015/>

37. Combining Constraint Programming and Machine Learning: From Current Progress to Future Opportunities - IRIS, accessed May 12, 2026, https://cris.unibo.it/retrieve/handle/11585/1056270/11df2215-4830-4234-9f71-ff730e766544/survey_CP_ML.pdf
38. Developing Constraint-based Recommenders - Department of Artificial Intelligence and Cybersecurity, accessed May 12, 2026, https://web-ainf.aau.at/pub/jannach/files/BookChapter_RS-Handbook-2010.pdf
39. Structural properties of individual instances predict human effort and performance on an NP-Hard problem - bioRxiv, accessed May 12, 2026, <https://www.biorxiv.org/content/10.1101/405449v3.full.pdf>
40. Do Humans Bargain Differently with AI? Evidence from Alternating-Offer Games, accessed May 12, 2026, https://www.researchgate.net/publication/404343030_Do_Humans_Bargain_Differently_with_AI_Evidence_from_Alternating-Offer_Games
41. Hindsight Bias - Petr Houdek, accessed May 12, 2026, https://houdekpetr.cz/data/public_html/papers/Roese%20et%20al%202012.pdf
42. Personalized Algorithmic Recourse with Preference Elicitation - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2205.13743v5>