

迈向隐性意图对齐：基于POMDP与显示偏好理论的“冰山画像”大模型交互评测基准的数学与经济学基础

1. 引言：大语言模型意图对齐的隐性维度与“冰山画像”的理论重构

在通用人工智能(Artificial General Intelligence, AGI)和复杂智能体(Agent)的演进历程中,“意图对齐(Intent Alignment)”始终是确保人工智能系统安全、可靠且符合人类价值观的核心命题。早期的对齐范式,如基于人类反馈的强化学习(Reinforcement Learning from Human Feedback, RLHF),极大地推动了大语言模型(LLM)在指令遵循(Instruction Following)和无害性(Harmlessness)方面的表现。然而,随着智能体被日益广泛地部署于高度复杂的现实决策场景——诸如医疗问诊、行程规划、复杂的志愿填报或商业谈判等,传统的静态问答对(Static QA)评测范式的局限性愈发凸显。这种范式存在一个根本性的理论缺陷:它假设人类的偏好是可以通过自然语言一次性、完备且精确地陈述出来的。但实际上,人类的真实偏好往往呈现出一种高度非线性和条件依赖的“冰山结构(Iceberg Profile)”¹。

在心理学和运动科学中,“冰山画像(Iceberg Profile)”最初被用于描述精英运动员在情绪状态量表(POMS)中展现出的高活力与低负面情绪的特征分布³。而在当代人工智能对齐与人机交互领域,这一概念被创新性地重构为一个隐喻,用以刻画用户意图的层次性结构:暴露在“水面之上”的,往往是用户为了降低沟通成本或出于防御心理而提出的显式、苛刻的绝对约束(例如,在择校时宣称“我绝不出省”);然而,“水面之下”则隐藏着庞大、复杂的隐性弹性偏好与底线(例如,“如果目标院校是顶尖985高校,且专业为极具前景的计算机科学,我愿意妥协去江苏”)。这类高阶的、条件触发式的偏好具有高度的上下文依赖性和不可通约性(Incommensurability),用户自身在面对具体的实体选项前,往往也难以通过自然语言准确地量化和表述这些隐藏的边际替代率(Marginal Rate of Substitution)⁷。

当前的大多数基准在衡量智能体的对齐能力时,通常仅仅测试其是否“听从了水面上的显式话语”。然而,真正具备高阶“心智理论(Theory of Mind, ToM)”的智能体,不应仅仅充当一个被动的指令执行器,更应当具备“主动偏好挖掘(Active Preference Elicitation)”的能力⁹。为了填补这一评测空白,“冰山画像”多轮沙盒评测基准(Benchmark)应运而生。在该基准体系中,被测Agent无法直接读取模拟器(Simulator)内部隐藏的真实效用函数(即隐性变量),它必须被置于一个反事实的沙盒环境中,通过检索底层的真实数据库,构建并抛出带有真实数据收益的对比方案(例如提出“江苏的985高校”),观察用户模拟器的反馈,从而主动触发并确认隐藏偏好的妥协。

本报告旨在从机器学习理论与微观经济学博弈论的交叉视角,为“冰山画像”评测机制提供严谨的学术与理论包装。本研究将把Agent挖掘冰山隐藏偏好的过程形式化为一个连续状态空间上的部分可观测马尔可夫决策过程(POMDP)和主动偏好推断的数学框架¹²。同时,从主动学习(Active Learning)中的版本空间(Version Space)缩减和期望信息增益(Expected Information Gain)的维度,运用信息论严格证明为何基于“帕累托权衡(Pareto Trade-off Queries)”的具体对比方案在消

除模型不确定性上远优于泛泛的开放式提问¹⁴。最后，引入微观经济学中的显示偏好理论 (Revealed Preference Theory)，论证为何高阶意图对齐能力必须在反事实沙盒中通过观察Agent“实际促成的选择”来评测，而非依赖其静态的自然语言表述²。通过这些跨学科的理论支柱，本报告将确立“冰山画像”作为下一代AGI心智与对齐评测黄金标准的学术合理性。

2. 隐性偏好挖掘的数学建模：主动偏好推断与POMDP框架

在“冰山画像”基准中，Agent与用户模拟器的多轮交互本质上是一个典型的序贯决策问题 (Sequential Decision-Making Problem)。由于用户的底层底线和弹性 (即隐藏的偏好参数) 对Agent是严格不可见的，并且Agent的每一次探询都会带来认知成本或交互摩擦，这一过程无法用标准的完全可观测马尔可夫决策过程 (MDP) 来描述，而必须被形式化建模为一个部分可观测马尔可夫决策过程 (Partially Observable Markov Decision Process, POMDP)¹²。

2.1 偏好启发POMDP的形式化元组定义

基于Boutilier (2002) 等人在偏好启发 (Preference Elicitation) 领域的经典工作¹³，结合现代大语言模型交互特征，我们可以将“冰山画像”探针挖掘过程定义为一个精确的六元组

$\langle S, A, T, R, \Omega, O \rangle$ 。这一框架为评估Agent的长期规划能力提供了完备的数学语言。

POMDP 元组元素	冰山画像评测基准中的映射定义	数学特性与约束说明
状态空间 (S)	用户的真实效用函数参数 (冰山水面下的隐性变量)。 设候选方案具有 K 维属性空间 $X =$, 效用函数参数化为 $\theta \in$ 。	连续高维空间 $\Theta \subset$ 。状态本质上是目标权重或非线性阈值向量。
动作空间 (A)	Agent的输出集, 包含探询动作 A_q (抛出对比方案) 和终结决策 A_d (输出最终匹配推荐)。即 $A = A_q \cup$ 。	混合动作空间。 A_q 代表探索 (Exploration), A_d 代表利用 (Exploitation)。
转移函数 (T)	$T(s' s, a)$ 。由于假设用户在单次交互Session内真实偏好是不变的 (无偏好漂移), 该过程是静态的。	恒等映射: $T(s' s, a) =$, 其中 δ 为指示函数 ¹³ 。

观测空间 (Ω)	用户的反馈信号。在沙盒中，体现为“接受(Accept)”、“拒绝并重申约束(Reject)”或“犹豫(Hesitate)”。	离散且带有噪音的语义反馈空间，需被映射为统计概率分布。
观测模型 (O)	$O(o s, a) =$ 。即在隐藏参数 θ 下，对方案 a 给出反馈 o 的概率分布。	传感器模型，通常采用Bradley-Terry模型或Luce选择规则进行构建 ²² 。
奖励函数 (R)	指导Agent行为的信号。探询动作带来交互成本 $-c(q)$ ，终结动作带来与用户真实效用相关的正向收益。	$R(\theta, a) = \int -c(a) \quad \text{if } a \in A_q$ 21

在这一严谨的结构下，状态空间 S 捕捉了问题的核心难点：多维连续参数空间带来了“维度灾难”，使得精确求解变得不可行。Agent必须在有限的交互轮数(预算约束)内，最小化对用户的认知干扰(表现为每次问询的成本惩罚 $c(a)$)，同时最大化最终推荐决策 a_d 的长期期望效用。

2.2 连续空间下的贝叶斯信念状态更新机制

由于Agent无法直接观察到隐性偏好 θ ，它必须在其计算内存或上下文窗口中维护一个关于 θ 的信念状态(Belief State)，记为 $b_t(\theta)$ 。该信念状态表示在 t 时刻，根据所有的历史交互轨迹 $H_t = \{a_0, o_0, \dots, a_{t-1}, o_{t-1}\}$ 所推导出的目标参数的后验概率密度函数¹²。

在“冰山画像”的交互循环中，当Agent从底层数据库检索并抛出一个带有真实数据收益的对比方案 a_t (例如，“去江苏上985高校”)，并观察到用户的反馈 o_t (例如，“如果能进计算机实验班，我就去”)后，Agent需调用贝叶斯定理(Bayes' Rule)对其信念空间进行精确更新：

$$b_{t+1}(\theta) = \frac{P(o_t|\theta, a_t)b_t(\theta)}{\int_{\Theta} P(o_t|\theta', a_t)b_t(\theta')d\theta'}$$

上述公式是Agent破译冰山底层的核心数学引擎。公式的分子部分 $P(o_t|\theta, a_t)$ 是基于特定随机效用模型计算的似然(Likelihood)。在现代主动偏好学习中，这一似然函数通常被建模为Bradley-Terry模型或具有相似对数几率特性的逻辑回归模型²³。该模型假设如果方案A的真实隐藏效用大于方案B，用户就有更高的概率选择或接受方案A。积分分母则充当归一化常数，确保信

信念状态是一个合法的概率分布。考虑到状态空间 Θ 的连续性，标准技术通常无法计算闭式解，因此高级Agent(或其背后的推断算法)需要依赖混合高斯模型(Mixture Models)或粒子滤波(Particle Filtering)等近似算法来维护这一信念更新过程¹³。

2.3 价值迭代与探索-利用困境的数学化解

通过上述信念更新过程，冰山水面下的不确定性被逐步剥离。Agent在这一POMDP环境下的最优

策略 π^* 是一个从信念状态空间到动作空间的映射函数 $\pi^* : \mathcal{B} \rightarrow \mathcal{A}$ 。根据贝尔曼方程(Bellman Equation)的动态规划原理，信念MDP的价值函数可以表示为期望效用与未来价值贴现之和¹³：

$$V(b) = \max \left\{ \max_{a_d \in \mathcal{A}_d} \int_{\Theta} U(x_{a_d}; \theta) b(\theta) d\theta, \max_{a_q \in \mathcal{A}_q} \left[-c(a_q) + \gamma \sum_{o \in \Omega} P(o|b, a_q) V(b_{a_q}^o) \right] \right\}$$

这一复杂的数学方程完美地封装了“冰山画像”中Agent面临的根本决策逻辑：它始终面临着一个经典的“探索与利用困境(Exploration-Exploitation Trade-off)”¹⁶。等式中的第一项代表利用(Exploitation)，即Agent根据当前的信念分布，直接做出一个终止对话的推荐决策；第二项代表探

索(Exploration)，即Agent选择承受一定的交互成本 $c(a_q)$ ，去提出一个诱人的妥协方案，以此来获取新的观测反馈，从而达到更新信念状态 $b_{a_q}^o$ 并增加未来收益期望的目的。

为了最大化长期累积效用并克服用户的显式表面言语误导，Agent必须执行那些能够最大程度切分信念空间的探询动作，从而成功触发隐藏偏好。如果一个被测LLM在沙盒中过早地做出了妥协或者仅能提供次优建议，从POMDP的视角来看，这表明该模型无法在长视野(Infinite Horizon)内正确计算探索的边际价值，其多轮规划与意图推断能力存在严重的系统性缺陷。

3. 帕累托对比方案的数学优势：信息增益与版本空间缩减

在评测实践中，一个关键的现象是：低阶或未充分对齐的Agent往往倾向于使用泛泛的开放式提问(Open-ended Questions)，例如：“您除了省内，还能接受去哪里的大学？”或者“您对专业有什么底线要求？”。然而，“冰山画像”基准在设计理念上，强制要求或鼓励Agent通过检索底层数据库，构建具体的对比方案(例如提出 Candidate A 具有更差的地理位置但更高的学校层级 vs. Candidate B 拥有更好的地理位置但较弱的专业排名)来进行探测。这种机制的设计并非出于偶然的直觉，而是深刻植根于主动学习(Active Learning)中版本空间(Version Space)理论与信息理论(Information Theory)的数学规律¹⁵。

3.1 基于开放式提问的认知负担与信息增益衰减

从香农信息论的角度来看，探询的目标是最大化信息的获取。在离散选择和偏好启发模型中，信息增益(Information Gain, IG)被定义为在观察到随机变量 A (用户反馈) 之后，关于目标变量 X (即隐藏偏好参数 θ) 的条件期望分布与先验分布之间的Kullback-Leibler (KL) 散度¹⁴：

$$EIG(X, A) = I(X; A) = H(X) - \mathbb{E}_{a \sim P(A)} [H(X|A = a)]$$

其中, $H(X)$ 是先验信念的熵, 代表系统初始的不确定性。期望信息增益 (EIG) 本质上衡量了特定提问能够在多大程度上降低模型对用户真实偏好的疑惑。

当Agent进行泛泛的开放式提问时, 存在三个导致严重“信息增益衰减”的致命缺陷:

1. 观测空间的极度宽泛与高熵: 用户的自然语言回答空间是近乎无限的, 包含了大量的冗余信息和语义噪音, 这使得似然函数 $P(o|\theta, a_{open})$ 难以被精确计算, 后验更新缺乏明确的方向性。
2. 过高的用户认知负担 (**Cognitive Load**): 行为经济学和认知心理学的研究表明, 人类在缺乏实际参照物 (锚点) 时, 往往难以内省并量化自身的真实偏好权重¹。开放式提问将搜寻整个可能解空间的计算负担转嫁给了用户, 导致交互成本 $c(a_q)$ 急剧上升³⁰。
3. 防御性回归: 在面对高认知负担的开放式问题时, 出于心理惰性, 用户模拟器 (及真实人类) 极易退回到“重申水面显式约束”的防御性回答中 (例如: “我之前说过了, 我绝不出省”)。这种回答导致的概率分布极其平缓 (Flat), 贝叶斯更新的梯度微弱, 期望信息增益趋近于零, 系统的不确定性未能得到实质性降低。

3.2 离散选择与版本空间的正交切分机制

相反, 当Agent抛出两个具体的候选方案进行对比 (或者提出一个虽然违背显式约束, 但在其他维度上提供了高额补偿的帕累托妥协方案) 时, 这在数学上等价于要求用户在多维参数空间中进行一次离散选择 (Discrete Choice)³¹。

假设 Agent 抛出方案 $X^{(1)}$ 和 $X^{(2)}$, 用户模拟器选择了 $X^{(1)}$ 。如果我们在最基础的线性效用函数框架下进行分析, 这一离散选择实际上向系统传达了一个确定性的代数不等式约束:

$$U(X^{(1)}) > U(X^{(2)}) \implies \theta \cdot X^{(1)} > \theta \cdot X^{(2)} \implies \theta \cdot (X^{(1)} - X^{(2)}) > 0$$

在主动学习和计算几何理论中, 所有与当前已知约束完全相符的假设 (即满足上述不等式的偏好向量 θ 的集合) 被称为版本空间 (**Version Space**) $\mathcal{V}$ ¹⁵。上述离散选择实际上在多维参数空间中定义了一个明确的几何结构: 一个通过原点 (或特定截距) 的超平面 (Hyperplane)

$$H = \{\theta \in \mathbb{R}^K | \theta \cdot (X^{(1)} - X^{(2)}) = 0\}^{27}.$$

这个超平面像一把精准的手术刀, 将现有的版本空间一分为二。根据主动学习中的不确定性采样 (Uncertainty Sampling) 和最大边距减少 (Maximum Margin Reduction) 原理, 如果Agent能够智能地选择对比方案, 使得差异向量 $(X^{(1)} - X^{(2)})$ 正交于当前版本空间的主轴, 或该超平面恰好穿过版本空间的质心 (Centroid), 那么这个问询对应的超平面将完美平分版本空间的体积²⁷:

$$\text{vol}(\mathcal{V}_{t+1}) \approx \frac{1}{2} \text{vol}(\mathcal{V}_t)$$

这一几何推导具有深远的启示意义：通过精心设计的“帕累托权衡(Pareto Trade-offs)”探测，版本空间的体积将随交互轮数呈指数级(Exponential)衰减。每一次具体的帕累托折中提议(例如：“牺牲省内地理位置约束，换取985名额与王牌专业”)，都极其锐利地切开了庞杂的参数空间。即便该提议被用户果断拒绝，Agent也能获得确定性的负样本区间信息，从而极大地缩小后续的搜索范围。理论界已经严格证明，这种基于成对比较(Pairwise Comparisons)的主动排序与偏好启发算法，能够利用最少的交互轮数(即 Query Complexity 为 $O(d \log(1/\epsilon))$)，其中 d 为属性维度)迅速收敛到真实的效用分布³⁶。

3.3 帕累托前沿(Pareto Front)与成本感知优化

进一步深入多目标优化(Multi-Objective Optimization, MOO)领域，帕累托权衡不仅在几何上高效，还在应对现实世界资源约束时具有不可替代的价值³⁹。在存在多个冲突目标(如“离家近”与“学校排名高”)的工程设计或推荐系统中，帕累托前沿(Pareto Front)代表了所有非支配(Non-dominated)解的集合⁴¹。

“冰山画像”要求Agent抛出的不仅仅是随意的方案组合，而是“带有真实数据收益的对比方案”。这意味着Agent需要在底层数据库中执行成本感知的优化(Cost-aware Optimization)，识别出近似的帕累托前沿。通过让用户在帕累托前沿上进行选择，Agent实际上迫使系统沿着费雪信息量(Fisher Information)最大的方向演进¹⁶。在这个过程中，系统不再纠结于次优解带来的噪音，而是直接逼问用户在“不可兼得”的极端情况下的真实偏好交换率⁴⁴。

因此，高阶Agent必须展现出识别底层数据供给能力、构建帕累托边界，并提取最优探询超平面的能力。这正是在消除模型不确定性上，具体对比方案拥有绝对数学优势的根源所在。

4. 显示偏好理论与反事实沙盒评测的微观经济学基础

在明确了寻找隐性偏好的最优数学与几何路径后，我们必须从根本上审视评测指标本身的合理性逻辑：为什么在评测大模型的意图对齐(Intent Alignment)或“心智理论(Theory of Mind)”能力时，学术界正呼吁不能仅仅依赖大模型在静态多轮问答(Static QA)中生成的文本回答，而必须考察其在反事实沙盒(Counterfactual Sandbox)中“实际促成了用户的何种选择”？这就需要跨界引入微观经济学中的核心公理——显示偏好理论(Revealed Preference Theory)。

4.1 陈述性偏好(Stated)与显示性偏好(Revealed)的本体论鸿沟

在经济学和行为科学中，评估消费者或个体的效用分布存在两种主要途径：陈述性偏好(Stated Preference, SP)和显示性偏好(Revealed Preference, RP)⁴⁶。

偏好评估范式	定义与方法论基础	局限性与在AI评测中的表现
--------	----------	---------------

陈述性偏好 (Stated Preference)	依赖问卷调查、访谈或直接对话。要求受试者“宣称”他们的偏好权重和意愿。对应于传统AI评测中的静态QA和提示词遵循。	极易受认知偏差、表达能力限制和“廉价沟通(Cheap Talk)”影响。受试者往往无法在无约束环境下表达真实的取舍 ² 。
显示性偏好 (Revealed Preference)	基于个体在面临真实价格或预算约束时做出的实际市场选择行为。对应于AI在带有底层资源限制的反事实沙盒中促成的最终交易。	要求构建复杂的约束环境(沙盒)，但能提供对隐含效用最真实、一致且具有抗欺骗性的数学推断 ² 。

长期以来的实证研究表明，陈述性偏好在刻画人类深层动机时往往是不可靠的¹。在没有资源约束或实际代价的语境下，模拟受试者的自然语言陈述容易表现出伪善，或者无法有效表达多属性之间的不可通约性(Incommensurability)⁷。例如，当问用户“地理位置和专业哪个重要”时，用户可能会说“都重要”或给出一个随意的排序；但当他们真正面临“清华的冷门专业”与“非985的热门专业”的选择时，其做出的行为决策往往背离了其先前的陈述。

早在20世纪，经济学家保罗·萨缪尔森(Paul Samuelson)提出的显示偏好理论便指出，由于内在的心理状态不可直接观测，个体的真实效用函数和偏好顺序，只能通过其不同预算约束条件下的实际选择行为来“显示”或推断，只要这些行为满足广义显示偏好公理(GARP)¹⁸。

将这一宏大的经济学理论映射到当代大模型的对齐评测中：如果一个Benchmark仅仅依靠静态的指令遵循(Instruction Following)或多轮闲聊来评测Agent，它实际上是在评测Agent处理“陈述性偏好”的能力。在“冰山画像”隐喻中，Agent仅仅在处理水面上的“显式苛刻话语”。这种评测范式下得分高的LLM，极可能只是训练出了极强的谄媚(Sycophancy)倾向，能够生成“听起来讨喜的文本”，而非真正理解了用户的内在诉求。然而，高维度的意图对齐不仅要求模型听懂用户“说了什么”，更要求模型在存在目标冲突(Blockage Problem)的复杂情境中，推理出用户“在面临真实且充满摩擦的现实权衡时会做什么”⁸。

4.2 反事实沙盒：测量高阶对齐的Luce对齐模型框架

为了准确捕捉这种深层的、行为驱动的对齐能力，“冰山画像”评测机制摒弃了静态文本，通过引入底层数据库构建了一个反事实沙盒(Counterfactual Sandbox)。这个沙盒本质上是一个微观经济学实验场。在这个沙盒中，Agent被置于客观的预算约束(即底层数据库中真实的方案供给限制)之中。在反事实数据(即数据库中故意不存完美的、100%满足显式要求的产品)中运作时，Agent的能力不仅体现在言语的同理心，而是体现在其动态提出的方案选择集(Menu of choices)能否在不违反用户隐含底线的情况下，最大化用户的潜在效用。

根据微观经济学与AI对齐交叉领域的最新研究(如Luce Alignment Model)¹⁷，Agent在意图对齐上的表现，可以通过分析其在沙盒中促成的随机选择概率分布来严格量化。

假设真实人类或完美代表人类心智的模拟器的选择行为，服从带有潜在效用函数 $u(x)$ 的Luce选择规则(Luce Rule)，而在沙盒实验中，Agent根据自身推断提出的候选方案促发了特定的交互

概率分布, 记为 $\rho_{AI}(x, S)$ 。在Luce对齐框架下, AI代理的选择可以被建模为两个Luce规则的混合物: 一个反映了人类的真实偏好, 另一个反映了AI自身的系统偏差或未对齐偏好。

通过对比纯粹自主运行的AI选择概率 ρ_{AI} 与人类主导的概率 ρ_H , 研究者可以解构出大模型

Agent的“合规水平(Compliance level, α)”与实质的“价值共识(Alignment, $v \approx \lambda u$)”²²。高阶Agent的意图对齐, 就是在给定的选择集结构约束下, 通过主动构建帕累托边界, 迫使隐性的真实效用 $u(x)$ 从用户的选择中“显示(Revealed)”出来, 并使得最终推荐结果的期望效用, 严格大于仅凭初始陈述偏好进行机械过滤所得到的结果。

因此, 静态QA无法衡量模型的心智理论(ToM)深度, 因为它缺乏促发行为选择的博弈机制和客观的经济代价; 唯有在反事实沙盒中, 基于显示偏好原理的结果导向型评价, 才能真正区分出一个LLM是仅仅擅长修辞, 还是真正具备了“洞察并在复杂环境约束下最大化隐性效用”的智能体决策能力¹。

5. 核心参考文献与前沿理论拓展

为支撑“冰山画像”评测基准的前瞻性与学术影响力, 并为相关研究者提供进一步探索的理论锚点, 以下系统梳理了近年来(尤其是2024-2025年间)在主动偏好启发、大语言模型隐性意图对齐以及基于心智理论的交互评测领域最具代表性的高影响力文献。这些文献从不同侧面印证了本文所构建理论框架的合理性。

5.1 主动偏好推断与在线对齐的算法机制

Wang (2024/2025). "Self-exploring language models: Active preference elicitation for online alignment." (ICLR 2025 / TMLR 2025).⁵³

- 理论贡献阐释: 这篇高影响力工作提出了大模型在线对齐中的自我探索框架。该研究明确将“主动偏好启发(Active Preference Elicitation)”的思想引入到语言模型的强化学习微调中。文章严格论证了, 通过赋予模型自我生成多样化、探索性回复的能力(其数学本质等价于抛出不同的候选对比方案)并在线获取偏好反馈, 能够系统性地消除偏好奖励模型(Reward Model)的预测不确定性。这一算法机制不仅在经验上提升了对齐效率, 更为本文将偏好探索过程封装为POMDP并追求最优期望信息增益(EIG)提供了直接的LLM前沿应用依据。

Zhao et al. (2024). "Active Preference Inference using Language Models and Probabilistic Reasoning." (arXiv:2312.12009).⁹

- 理论贡献阐释: 该研究深入探讨了结合大语言模型和概率推理技术, 在推理时(Inference-time)进行主动偏好推断的算法设计。其核心创新在于, 算法摒弃了被动的上下文理解, 转而通过最大化预期模型变化(Expected Model Change)和期望熵(Expected Entropy)来生成最具信息量(Informative)的提问策略。该文献的实证结果完美地佐证了本文在第3节中的数学推演: 精心设计的探索性问询在缩减假设版本空间、加速对齐收敛速度上的能力, 远远超越了常规语言模型“开箱即用”时所产生的冗杂提问。

5.2 显示偏好理论与经济学视角的AI评估

Chen et al. (2024/2025). "A Revealed Preference Framework for AI Alignment." (arXiv:2603.27868).¹⁷

- 理论贡献阐释: 这是将微观经济学经典理论引入AI安全与对齐领域的里程碑式文献。该论文首次将显示偏好理论和Luce对齐模型严格数学化, 并应用于AI对齐程度的定量评估中。文章详尽地推导了如何在实验室设定 (Laboratory Setting, 人机双向可观测) 和现场数据 (Field Data) 下, 通过观测AI在预算分配等博弈任务中实际促成的随机选择不稳定比例, 来反向识别其隐藏的意图对齐度。该研究为“冰山画像”评测基准“摒弃静态QA、转向基于沙盒反馈的行为经济学评测机制”提供了无可辩驳的核心经济学公式与公理支持。

He, Shorrer, & Xia (2025). "Should I State or Should I Show? Aligning AI with Human Preferences.".²

- 理论贡献阐释: 这是一项针对人类与AI交互行为的最新实验研究。研究者通过对比实验发现, 基于“显示偏好”(即向AI提供人类过去的行为决策数据)在准确预测和对齐用户真实意愿方面, 显著优于基于“陈述偏好”(即让用户直接书写提示词或要求)。更令人警醒的是, 当面临两种偏好预测结果冲突时, 缺乏复杂推断机制的AI往往会顺从不准确的“陈述偏好”。该研究以坚实的实证数据证明: 人类极难通过显式话语完美刻画自身的隐性意图。因此, 评测大模型高阶对齐能力的前提, 必须是构建一个迫使其依赖行为反馈进行推断的反事实环境。

5.3 交互式心智理论基准的范式转移

Interactive Theory of Mind (ToM) Benchmarks for LLMs (2024-2025). (e.g., MOTIVEBENCH).⁵⁷

- 理论贡献阐释: 随着对大模型社会认知能力研究的深入, 关于心智理论 (Theory of Mind, ToM) 的评测正经历剧烈的范式转移。最新的综合评述与基准提案明确指出, 评估ToM应从传统的基于静态虚构故事文本 (Story-based text comprehension, 如Sally-Anne测试的变体) 大步迈向基于多智能体博弈的交互式沙盒 (Interactive & Sandbox) 测试。真正的ToM不仅涉及识别表面情绪状态, 更涉及在目标冲突、资源受限和信息不对称的动态环境中, 准确理解对方隐性“动机 (Motive)”并采取鲁棒的策略响应。“冰山画像”正是顺应并引领这一学术趋势的典型代表结构。

6. 结论

“冰山画像”多轮沙盒评测基准在看似工程化、任务导向的测试流程背后, 蕴含着极为深刻的机器学习数学原理与微观经济学基础。随着人工智能系统自主性的提升, 传统的基于指令遵循和文本匹配的评测维度已不足以保障系统的安全性和意图的精确对齐。

本文通过详尽的学术重构, 证明了该基准的三大核心理论支柱。首先, 通过将大语言模型挖掘隐性弹性的交互过程建模为带有贝叶斯信念更新的部分可观测马尔可夫决策过程 (POMDP), 我们从计算理论的高度明晰了: 由于用户真实效用函数 (冰山底层) 的不可见性, 高阶Agent必须跨越“探索与利用”的困境, 具备长期的不确定性管理与概率推断能力。

其次，借助于版本空间切分理论与期望信息增益的严格数学框架，本文论证了系统设计为何强调模型需主动抛出“带有真实数据收益的帕累托对比方案”，而非依赖泛泛的开放式探测。前者将连续且高熵的语义探寻，精妙地转化为高维参数空间中极度锐利的超平面离散选择约束，从而以指数级的效率逼近用户的真实效用边界。

最后，结合微观经济学中经典的显示偏好理论 (**Revealed Preference Theory**)，本文从本体论层面澄清了高阶意图对齐无法通过静态QA环境下的陈述性偏好来验证的本质原因。人类偏好的不可通约性与表达摩擦，要求我们必须构建存在资源约束和权衡机制的反事实沙盒。唯有通过严格观测Agent在该沙盒中实际促成的决策轨迹与最终选择分布，才能真正丈量AGI在“心智理论”与深层价值共识上的真实能力边界。

综上所述，这一涵盖运筹学、信息论与行为经济学的理论封装，不仅巩固了“冰山画像”基准在学术研究与评价体系中的严谨性，更为未来复杂场景下的模型隐性价值对齐技术指明了清晰的理论方向。

Works cited

1. Should I State or Should I Show? Aligning AI with Human Preferences - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2603.29317v1>
2. Should I State or Should I Show? Aligning AI with Human Preferences - ResearchGate, accessed May 12, 2026, https://www.researchgate.net/publication/403379496_Should_I_State_or_Should_I_Show_Aligning_AI_with_Human_Preferences
3. hosmer-lemeshow goodness-of-fit test: Topics by Science.gov, accessed May 12, 2026, <https://www.science.gov/topicpages/h/hosmer-lemeshow+goodness-of-fit+test>
4. International Journal of Sport and Exercise Psychology (IJSEP), accessed May 12, 2026, https://issponline.org/wp-content/uploads/2021-ISSP_15th-World-Congress-Proceeding.pdf
5. The Iceberg Profile Does Not Influence the Performance of Elite League of Legends Players, but Changes With the Events of the Game - ResearchGate, accessed May 12, 2026, https://www.researchgate.net/publication/378991314_The_Iceberg_Profile_Does_Not_Influence_the_Performance_of_Elite_League_of_Legends_Players_but_Changes_with_the_Events_of_the_Game
6. IDENTIFICATION AND ENHANCEMENT OF PRE PERFORMANCE MENTAL STATES IN MALE RUGBY UNION PLAYERS STEPHEN DAVID IVELLALIEU - University of Gloucestershire, accessed May 12, 2026, <https://eprints.glos.ac.uk/5694/1/Mellalieu%20Thesis.pdf>
7. Decision Theory FAQ - LessWrong, accessed May 12, 2026, <https://www.lesswrong.com/posts/zEWJBFFMvQ835nq6h/decision-theory-faq>
8. AI Agents and Hard Choices - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2504.15304v2>
9. Active Preference Inference using Language Models and Probabilistic Reasoning - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2312.12009v1>

10. Active Preference Inference using Language Models and Probabilistic Reasoning - arXiv, accessed May 12, 2026, <https://arxiv.org/abs/2312.12009>
11. Computational Approaches to Preference ... - Darius Braziunas, accessed May 12, 2026, <https://dariusb.bitbucket.io/papers/PreferenceElicitation.pdf>
12. Partially observable Markov decision process - Wikipedia, accessed May 12, 2026, https://en.wikipedia.org/wiki/Partially_observable_Markov_decision_process
13. A POMDP Formulation of Preference Elicitation Problems - ResearchGate, accessed May 12, 2026, https://www.researchgate.net/publication/2553765_A_POMDP_Formulation_of_Prference_Elicitation_Problems
14. Information gain (decision tree) - Wikipedia, accessed May 12, 2026, [https://en.wikipedia.org/wiki/Information_gain_\(decision_tree\)](https://en.wikipedia.org/wiki/Information_gain_(decision_tree))
15. Effective Version Space Reduction for Convolutional Neural Networks - Computer Vision Group, accessed May 12, 2026, https://cvg.cit.tum.de/_media/spezial/bib/liu2020effective.pdf
16. 4 Decisions - Machine Learning from Human Preferences, accessed May 12, 2026, <https://mlhp.stanford.edu/src/chap4.html>
17. A Revealed Preference Framework for AI Alignment - IDEAS/RePEc, accessed May 12, 2026, <https://ideas.repec.org/p/arx/papers/2603.27868.html>
18. What Do LLMs Want? - Federal Reserve, accessed May 12, 2026, <https://www.federalreserve.gov/econres/feds/files/2026006pap.pdf>
19. POMDP solution methods - Darius Braziunas, accessed May 12, 2026, https://dariusb.bitbucket.io/papers/POMDP_survey.pdf
20. Computational Decision Support: Regret-based Models for Optimization and Preference Elicitation, accessed May 12, 2026, https://www.cs.toronto.edu/~cebly/Papers/RegretBasedModels_ComparativeDM_chapter.pdf
21. A POMDP Formulation of Preference Elicitation Problems - Department of Computer Science, University of Toronto, accessed May 12, 2026, https://www.cs.toronto.edu/~cebly/Papers/download/_pefa.pdf
22. A Revealed Preference Framework for AI Alignment - arXiv, accessed May 12, 2026, <https://arxiv.org/pdf/2603.27868>
23. A Reduced Basis Decomposition Approach to Efficient Data Collection in Pairwise Comparison Studies - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2512.19398v2>
24. Pairwise Comparison Modeling - Michael Betancourt, accessed May 12, 2026, https://betanalpha.github.io/assets/chapters_pdf/pairwise_comparison_modeling.pdf
25. Preference Learning of Latent Decision Utilities with a Human-like Model of Preferential Choice - NIPS papers, accessed May 12, 2026, https://proceedings.neurips.cc/paper_files/paper/2024/file/df559d92fba6dc86dec1a2be59ebfce3-Paper-Conference.pdf
26. The Permutable POMDP: Fast Solutions to POMDPs for Preference Elicitation - Research, accessed May 12, 2026, <https://groups.csail.mit.edu/rrg/papers/aamas08-fd.pdf>

27. Active Learning with Kernel Machines, accessed May 12, 2026, <https://d-nb.info/974403946/34>
28. Information Gain and Mutual Information for Machine Learning - MachineLearningMastery.com, accessed May 12, 2026, <https://machinelearningmastery.com/information-gain-and-mutual-information/>
29. Active Data Selection and Information Seeking - MDPI, accessed May 12, 2026, <https://www.mdpi.com/1999-4893/17/3/118>
30. Heuristics for prioritizing pair-wise elicitation questions with additive multi-attribute value models | Request PDF - ResearchGate, accessed May 12, 2026, https://www.researchgate.net/publication/308418994_Heuristics_for_prioritizing_pair-wise_elicitation_questions_with_additive_multi-attribute_value_models
31. Discrete choice experiments: a primer for the communication researcher - Frontiers, accessed May 12, 2026, <https://www.frontiersin.org/journals/communication/articles/10.3389/fcomm.2025.1385422/full>
32. Entropy Guided Diversification and Preference Elicitation in Agentic Recommendation Systems - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2603.11399v1>
33. Noise-Tolerant Interactive Learning Using Pairwise Comparisons - NIPS, accessed May 12, 2026, <http://papers.neurips.cc/paper/6837-noise-tolerant-interactive-learning-using-pairwise-comparisons.pdf>
34. Preference elicitation for interface optimization - DASH (Harvard), accessed May 12, 2026, <https://dash.harvard.edu/bitstreams/7312037d-d2ac-6bd4-e053-0100007fdf3b/download>
35. Active Learning Query Selection with Historical Information, accessed May 12, 2026, <https://publications.scss.tcd.ie/tech-reports/reports.13/TCD-CS-2013-03.pdf>
36. Learning Populations of Preferences via Pairwise Comparison Queries, accessed May 12, 2026, <https://proceedings.mlr.press/v238/tatli24a/tatli24a.pdf>
37. Active ranking from pairwise comparisons and when parametric assumptions do not help - Project Euclid, accessed May 12, 2026, <https://projecteuclid.org/journals/annals-of-statistics/volume-47/issue-6/Active-ranking-from-pairwise-comparisons-and-when-parametric-assumptions-do/10.1214/18-AOS1772.pdf>
38. Passive and Active Ranking from Pairwise Comparisons - Computer Science, accessed May 12, 2026, https://cseweb.ucsd.edu/~yansongbai/files/research_exam.pdf
39. Estimating Decision Uncertainty from Preference Uncertainty: Application to Ground Vehicle Design - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2604.27243v1>
40. Pareto domain: an invaluable source of process information - PMC, accessed May 12, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9028026/>

41. Pareto-optimal vs satisficing in engineering design - PatSnap, accessed May 12, 2026,
<https://www.patsnap.com/resources/blog/articles/pareto-optimal-vs-satisficing-in-engineering-design/>
42. Pareto optimization with small data by learning across common objective spaces - PMC, accessed May 12, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC10185551/>
43. 7 Conclusion - Machine Learning from Human Preferences, accessed May 12, 2026, <https://mlhp.stanford.edu/src/chap7.html>
44. QUIVER: Cost-Aware Adaptive Preference Querying in Surrogate-Assisted Evolutionary Multi-Objective Optimization - arXiv, accessed May 12, 2026,
<https://arxiv.org/pdf/2605.04267>
45. A Non-Bayesian Preference Elicitation Approach for Noisy Decision Models - CORA, accessed May 12, 2026,
<https://cora.ucc.ie/bitstreams/abf97a18-b2ff-4bbc-bae4-93f9ceb50ec0/download>
46. The problem of behaviour and preference manipulation in AI systems - CEUR-WS.org, accessed May 12, 2026, https://ceur-ws.org/Vol-3087/paper_28.pdf
47. Stated preference methods and STI policy studies: a foreground approach | Research Evaluation | Oxford Academic, accessed May 12, 2026,
<https://academic.oup.com/rev/article/32/2/171/7252884>
48. Cardinal Welfare, Individualistic Ethics, and Interpersonal Comparisons of Utility | Journal of Political Economy: Vol 63, No 4, accessed May 12, 2026,
<https://www.journals.uchicago.edu/doi/abs/10.1086/257678?journalCode=jpe>
49. A Worldwide Test of the Predictive Validity of Ideal Partner Preference-Matching - PMC - NIH, accessed May 12, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC12622239/>
50. A Revealed Preference Framework for AI Alignment - ResearchGate, accessed May 12, 2026,
https://www.researchgate.net/publication/403307286_A_Revealed_Preference_Framework_for_AI_Alignment
51. A Revealed Preference Framework for AI Alignment - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2603.27868v1>
52. LLMs4All: A Review of Large Language Models Across Academic Disciplines - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2509.19580v5>
53. Less is More: Improving LLM Alignment via Preference Data Selection - arXiv, accessed May 12, 2026, <https://arxiv.org/html/2502.14560v4>
54. ICML Poster Understanding the Logic of Direct Preference Alignment through Logic, accessed May 12, 2026, <https://icml.cc/virtual/2025/poster/46481>
55. Avoiding exp(R) scaling in RLHF through Preference-based Exploration | OpenReview, accessed May 12, 2026,
<https://openreview.net/forum?id=TMSNIEKKeM>
56. Personalizing Reinforcement Learning from Human Feedback with Variational Preference Learning - NIPS papers, accessed May 12, 2026,
https://proceedings.neurips.cc/paper_files/paper/2024/file/5e1c255653eb98cef13f

[45b2d337c882-Paper-Conference.pdf](#)

57. Theory of Mind in Large Language Models: Assessment and Enhancement - ACL Anthology, accessed May 12, 2026,
<https://aclanthology.org/2025.acl-long.1522.pdf>
58. LLMsPark: A Benchmark for Evaluating Large Language Models in Strategic Gaming Contexts - arXiv, accessed May 12, 2026,
<https://arxiv.org/html/2509.16610v1>
59. MOTIVEBENCH: How Far Are We From Human-Like Motivational Reasoning in Large Language Models? - ACL Anthology, accessed May 12, 2026,
<https://aclanthology.org/2025.findings-acl.1029.pdf>